



SAPIENZA
UNIVERSITÀ DI ROMA

Un tool per la ricerca di virtual patient in biomchemical network

Facoltà di Ingegneria dell'informazione, informatica e statistica
Laurea triennale in Informatica

Luca Sforza

Matricola 2050030

Relatore

Prof. Enrico Tronci

Anno Accademico 2024/2025

Tesi discussa il 24 Gennaio 2024

di fronte a una commissione esaminatrice composta da:

Prof. Tizio (presidente)

Prof. Caio

Prof. Sempronio

Prof. ...

Prof. ...

Prof. ...

Prof. ...

Un tool per la ricerca di virtual patient in biomchemical network

Relazione di Tirocinio. Sapienza Università di Roma

© 2025 Luca Sforza. Tutti i diritti riservati

Questa tesi è stata composta con L^AT_EX e la classe Sapthesis.

Email dell'autore: sforza.2050030@studenti.uniroma1.it

«Tutti i modelli sono sbagliati, ma alcuni sono utili.»
— *George E. P. Box*

Sommario

Contesto

Obbiettivi

Metodi

Risultati

Indice

Acronomi	vi
1 Introduzione	1
1.1 Contesto e Motivazioni	1
1.2 Contributi	1
1.3 Stato dell'arte	2
1.4 Struttura della Relazione di Tirocinio	2
2 Modellazione Biologica	3
2.1 Introduzione	3
2.2 modelli biologici di Pathway	4
3 Stima dei parametri	5
3.1 Vincoli sui parametri	5
3.2 Come trovare i parametri	8
4 Progettazione del tool	9
4.1 Algoritmo	9
5 Esempi di modelli	11
5.1 Cellule staminali mammarie	11
5.2 Ripiegamento proteico mediato da chaperoni nel cancro	11
5.3 Mutazione IDH1 e produzione di 2-idrossiglutarato (R-HSA-2978092)	13
5.4 Regolazione dell'apoptosi tramite ubiquitinazione proteica (R-HSA-169911)	13
5.5 Patologie legate alla risposta cellulare allo stress	13
6 Conclusione	14
6.1 Innovatività della ricerca	14
6.2 Potenzialità di realizzare un avanzamento delle conoscenze	14
Glossario	15
Bibliografia	16
Figure	17
Ringraziamenti	17

Elenco delle figure

3.1	Visualizzazione del transitorio	6
4.1	UML	10
5.1	Rappresentazione del modello: R-HSA-9938206	11
5.2	A sinistra c'è l'ottimizzazione fatta da Nevergrad dei parametri e a destra invece la simulazione.	12
5.3	Rappresentazione del modello: R-HSA-390471	12
5.4	A sinistra c'è l'ottimizzazione fatta da Nevergrad dei parametri e a destra invece la simulazione.	12

Elenco delle tabelle

Capitolo 1

Introduzione

1.1 Contesto e Motivazioni

Tutti gli esseri viventi sono costituiti da cellule, piccole fabbriche biochimiche che attraverso dei metabolismi consumano energia per esistere.

Studiare le cellule e il loro funzionamento è fondamentale per comprendere malattie nel corpo umano, come il cancro.

Una cellula nella sua interezza è un sistema biologico governato da reti complesse di interazioni tra molecole come proteine, metaboliti e acidi nucleici.

Tuttavia si possono studiare solo piccoli parti di questi network metabolici, ovvero i pathway che vanno a studiare una specifica funzione di una cellula.

Esistono online database di pathway che possono essere resi simulabili modellando le reazioni come equazioni differenziali ordinarie (ODE).

L'accuratezza di queste simulazioni dipende in modo cruciale dalle costanti cinetiche che governano le reazioni. Tali parametri risultano spesso difficili o impossibili da misurare sperimentalmente, lasciando un ampio margine di incertezza nei modelli.

Però esiste il concetto di **paziente virtuale** inteso come una collezione di modelli computazionali che rappresentano diversi possibili scenari biologici compatibili con le conoscenze disponibili.

1.2 Contributi

Con questa relazione di tirocinio, si vuole presentare un software che, dato un modello biologico, permette di individuare pazienti virtuali plausibili, ovvero insiemi di parametri coerenti con i vincoli biologici.

In particolare, il lavoro introduce un framework computazionale per l'esplorazione degli spazi di parametri cinetici in reti biochimiche. I contributi principali sono:

1. Algoritmo per verificare l'esistenza di assegnazioni dei parametri che soddisfino le condizioni di stato stazionario e riproducano l'ordinamento relativo delle concentrazioni delle specie.
2. Implementazione software integrata con librerie di simulazione consolidate, che garantisca riproducibilità ed estendibilità.

3. Implementazione di un algoritmo evolutivo di OpenAI per l'ottimizzazione black-box.

1.3 Stato dell'arte

1.4 Struttura della Relazione di Tirocinio

- Capitolo 2 presenta il background teorico sulla modellazione di reti biochimiche.
- Capitolo 3 descrive la formulazione del problema e i vincoli usati per definire le assegnazioni di parametri ammissibili.
- Capitolo 4 Illustra l'algoritmo di OpenAI come uno dei possibili per trovare i parametri
- Capitolo 5 Introduce la progettazione del software e le dipendenze utilizzate per crearlo.
- Capitolo 6 si presentano degli utilizzi su 5 modelli biologici presi da Reactome.
- Capitolo 7 considerazioni finali e possibili sviluppi futuri.

Capitolo 2

Modellazione Biologica

2.1 Introduzione

I modelli biologici che consideriamo sono sistemi dinamici tempo-invarianti, generalmente non lineari, descritti da equazioni differenziali ordinarie (ODE).

Lo stato del sistema al tempo t è un vettore $x(t) = (x_1(t), \dots, x_n(t))^T \in [0, 1]^n \subseteq \mathbb{R}^n$, dove $x_i(t)$ rappresenta la concentrazione normalizzata della i -esima specie. Poiché le concentrazioni sono normalizzate, $x_i(t) \in [0, 1]$ per ogni i e ogni t .

In forma compatta le ODE si scrivono

$$\frac{dx}{dt} = f(t, x).$$

Sia m il numero di reazioni nel modello.

Per ogni specie x_i definiamo $R_{x_i} \subseteq \{1, \dots, m\}$ (reazioni in cui x_i è reattante), $P_{x_i} \subseteq \{1, \dots, m\}$ (reazioni che producono x_i).

Se $R_{x_i} \neq \emptyset$ e $P_{x_i} \neq \emptyset$, l'evoluzione temporale di x_i è data da:

$$\frac{dx_i}{dt} = \sum_{j \in P_{x_i}} v_j(t) - \sum_{j \in R_{x_i}} v_j(t),$$

dove $v_j(t)$ è la velocità della reazione j .

La velocità di una reazione è data dalla legge dell'azione di massa (mass action).

La velocità di una reazione chimica è proporzionale al prodotto delle concentrazioni dei reagenti, ciascuna elevata al proprio coefficiente stechiometrico

La velocità di una reazione è influenzata da modificatori (enzimi, inibitori). Per modellare l'effetto dei modificatori si usa spesso la funzione di Hill. Per ogni specie modificatrice x_ℓ introduciamo una funzione di Hill generica

$$H_\ell(t) = \begin{cases} \frac{x_\ell(t)^{10}}{K_\ell + x_\ell(t)^{10}}, & \text{se } x_\ell \text{ agisce da attivatore,} \\ \frac{K_\ell}{K_\ell + x_\ell(t)^{10}}, & \text{se } x_\ell \text{ agisce da inibitore,} \end{cases}$$

dove $K_\ell > 0$ è la costante di mezzo-saturazione e dato che è ignota viene aggiunta come parametro del modello.

Per la reazione $i \in \{1, \dots, m\}$ definiamo inoltre:

$S_i = \{j \in \{1, \dots, n\} \mid x_j \text{ è reattante della reazione } i\}$,

$M_i = \{j \in \{1, \dots, n\} \mid x_j \text{ è modificatore della reazione } i\}$.

n_i^j è la stochiometria della specie j nella reazione i .

La velocità $v_i(t)$ si esprime quindi come

$$v_i(t) = k_i \prod_{j \in S_i} x_j(t)^{n_i^j} \prod_{j \in M_i} H_j(t),$$

dove $k_i > 0$ è la costante cinetica della reazione. Essa essendo sconosciuta viene aggiunta come parametri del modello.

2.2 modelli biologici di Pathway

Un pathway metabolico (o via metabolica) è una sequenza di reazioni biochimiche che collega metaboliti chiave.

Un pathway è formato da specie di input che non vengono prodotte da reazioni, ma vengono immesse nel pathway. Specie intermedie che sono sia prodotte che consumate da reazioni, specie di output che sono solo prodotte da reazioni e mai consumate e specie che non vengono né prodotte né consumate da alcuna reazione, ma sono enzimi o inibitori che influiscono nelle altre reazioni.

Un esempio tipico di input è l'ATP che funge da "energia" per molte reazioni chimiche.

Esse non vengono prodotte da reazioni ($P_{x_i} = \emptyset$) ma vengono immesse nel sistema; si modellano con un termine di ingresso costante $k_{\text{in},i}$:

$$\frac{dx_i}{dt} = k_{\text{in},i} - \sum_{j \in R_{x_i}} v_j(t).$$

I pathway hanno degli output che sono specie che vengono prodotte ma non consumate ($R_{x_i} = \emptyset$); ad esse si aggiunge una reazione di degradazione, che avrà una costante cinetica e ha come unico reattante la concentrazione dell'output stesso, quindi seguendo la mass action rule l'equazione differenziale per gli output è come segue:

$$\frac{dx_i}{dt} = \sum_{j \in P_{x_i}} v_j(t) - k_{\text{out},i} x_i(t),$$

Nei modelli biologici di pathway possono essere presenti specie che non partecipano né come reattanti né come prodotti alle reazioni, ma solo come modificatori. Quindi queste specie devono avere una costante di immissione ed anche una di degradazione.

Queste specie sono enzimi o inibitori esterni, quindi influiscono sulla velocità delle altre reazioni del modello. La loro dinamica è descritta come segue:

$$\frac{dx_i}{dt} = k_{\text{in},i} - k_{\text{out},i} x_i(t).$$

Capitolo 3

Stima dei parametri

Le costanti cinetiche e gli altri parametri (es. K_ℓ , $k_{\text{in},i}$, $k_{\text{out},i}$) sono generalmente sconosciuti e devono essere stimati. Poiché i parametri cinetici possono variare di molti ordini di grandezza, è comune parametrizzarli in scala logaritmica. Se p è il numero totale di parametri, si può usare un vettore di parametri $\theta \in [-20, 20]^p \subseteq \mathbb{Z}^p$.

Da notare che il dominio dei parametri è non solo discreto, ma addirittura finito. Questo ci permetterà di cercare tutti i parametri che rispettano determinati vincoli.

Per ricavare la costante cinetica a partire dal parametro logaritmico si usa la parametrizzazione in base dieci:

$$k_i = 10^{\theta_i}, \quad \theta_i \in [-20, 20],$$

così θ_i rappresenta $\log_{10} k_i$ e si garantisce $k_i > 0$.

Prima di stimare i parametri bisogna aggiungere dei vincoli su di essi.

Si può fare in due modi: o limitando il dominio delle costanti cinetiche eliminando quelle implausibili oppure definendo una funzione che dati i parametri valutano l'errore all'interno del modello, poi tramite un ottimizzatore black box si trovano i parametri che minimizzano l'errore.

Per l'esame di **intelligenza artificiale** su cui si basa il progetto del tirocinio è stato mostrato quale algoritmo dell'ottimizzatore Nevergrad converge più velocemente su un modello particolare e semplificato.

3.1 Vincoli sui parametri

I parametri da scegliere devono soddisfare determinati requisiti.

Primo tra tutti i parametri devono rendere il sistema stabile.

Quindi bisogna notare il fatto che gli enzimi o inibitori di una reazione controllano il comportamento di quella reazione.

Quindi una condizione necessaria, ma non sufficiente per la stabilità è che le costanti cinetiche che producono modificatori (enzimi o inibitori) devono essere maggiori delle costanti cinetiche che i modificatori alterano.

Formalmente sia:

$$R = \{(i, j) \in [1, m]^2 \mid \text{la reazione } i \text{ produce un modificatore della reazione } j\}$$




Figura 3.1 Visualizzazione del transitorio

Allora l'ottimizzatore deve rispettare questi vincoli che limitano lo spazio feaseble dei parametri:

$$k_i \geq k_j \mid (i, j) \in R \quad (3.1)$$

Per vincolare definitivamente la stabilità bisogna eliminare il transitorio. Il transitorio è la parte iniziale del sistema in cui i valori non sono ancora stabili.

Per capire cos'è il transitorio dobbiamo definire cos'è la concentrazione media di una specie.

Definiamo T come l'orizzonte di simulazione.

La concentrazione di una specie non dipende solo dal tempo, ma anche dai parametri, quindi la concentrazione di una specie è: $x_i(t, \theta)$.

La concentrazione media di una specie i è definita come segue:

$$\tilde{x}_i(t', \theta) = \mathbb{E}_{\tau \sim \mathcal{U}(0, t')} [x_i(\tau, \theta)] = \frac{1}{t'} \int_0^{t'} x_i(\tau, \theta) d\tau, \quad t' > 0. \quad (3.2)$$

Il transitorio quindi è il segmento tra i due valori medi $\tilde{x}_i(\phi \cdot T, \theta)$ e $\tilde{x}_i(T, \theta)$.

ϕ è un iper-parametro dell'ottimizzatore, per lo scopo del tirocinio è stato scelto $\phi = \frac{1}{2}$.

Per vincolare l'eliminazione del transitorio definiamo una funzione da minimizzare:

$$\mathcal{L}_1(\theta) = \sum_{i=1}^n (\tilde{x}_i(\phi \cdot T, \theta) - \tilde{x}_i(T, \theta))^2 \quad (3.3)$$

Minimizzare $\mathcal{L}_1$ significa eliminare il transitorio e quindi vincolare la stabilità del sistema.

Per poter visualizzare che cos'è il transitorio in figura 3.1 è presente un esempio.

Un altro vincolo sulle costanti cinetiche è che devono far rimanere il valore delle concentrazioni tra 0 e 1, poiché per ipotesi la concentrazioni delle specie sono tutte normalizzate.

Per fare ciò dobbiamo aggiungere delle nuove variabili allo stato per ogni specie esistente, con la relativa equazione differenziale:

z_i è la nuova variabile dello stato associato alla specie x_i .

$$\frac{dz_i}{dt} = \text{if } x_i(t, \theta) \geq 1 \vee x_i(t, \theta) \leq 0 \text{ then } 10 \text{ else } 0 \quad (3.4)$$

Quindi per vincolare le specie tra 0 e 1 dobbiamo minimizzare il valore di queste variabili.

$$\mathcal{L}_2(\theta) = \sum_{i=1}^n z_i(T, \theta) \quad (3.5)$$

I parametri delle costanti cinetiche non solo devono garantire la stabilità, ma devono anche garantire varie regole biologiche. Per esempio l'acqua è il solvente della vita, tutto ciò che è presente dentro una cellula è immerso nell'acqua. L'acqua quindi è sempre la specie più espressa all'interno di un modello biologico.

L'acqua è solo un esempio, ma esistono molti motivi del perché si vuole vincolare che una certa specie è più espressa di un'altra.

Definiamo quindi una relazione di ordinamento sulle specie $R \subseteq [1, n]^2$.

Se $(i, j) \in R$ allora la specie j deve essere più espressa della specie i .

Definiamo una nuova funzione da minimizzare $\mathcal{L}_3$.

$$\mathcal{L}_3(\theta) = \sum_{(i,j) \in R} \max(0, \tilde{x}_i(T, \theta) - \tilde{x}_j(T, \theta)) \quad (3.6)$$

Altri vincoli da aggiungere sono vincolare il valore medio di una concentrazione ad una certa costante nota.

Supponiamo di avere un dataset:

$$\mathcal{D} = \{y_i \in [0, 1] \mid y_i \text{ è la concentrazione media osservata della specie } i\}.$$

Un modo per vincolare i parametri a questi dati è massimizzando la **likelihood** dei parametri.

La likelihood è la probabilità condizionata di osservare dal modello il dato osservato se il modello è corretto.

Più formalmente:

$$L(\theta \mid \mathcal{D}) = \mathbb{P}(\mathcal{D} \mid \theta) \quad (3.7)$$

Quindi i parametri da scegliere devono essere quelli che massimizzano la likelihood.

$$\hat{\theta}(\mathcal{D}) = \arg \max_{\theta} L(\theta \mid \mathcal{D}) \quad (3.8)$$

Ma in pratica per ottenere questi parametri dobbiamo fare delle ipotesi.

I dati osservati $\mathcal{D}$ per ipotesi devono provenire da repliche sperimentali indipendenti ottenute nelle stesse condizioni sperimentali del modello e affette da rumore osservazionale. Tipicamente si assume un errore additivo gaussiano sulle medie osservate:

$$y_i = \tilde{x}_i(T, \theta) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_i^2),$$

dove σ_i^2 è la varianza dell'errore per la specie i . Sotto questa ipotesi la log-likelihood del dataset è

$$\log L(\theta \mid \mathcal{D}) = -\frac{1}{2} \sum_{y_i \in \mathcal{D}} \left[\frac{(y - \tilde{x}_i(T, \theta))^2}{\sigma_i^2} + \log(2\pi\sigma_i^2) \right].$$

La stima dei parametri si ottiene massimizzando questa funzione (o minimizzando la somma dei residui normalizzati).

Quindi definiamo una nuova funzione da minimizzare $\mathcal{L}_4$.

$$\mathcal{L}_4(\theta) = \sum_{y_i \in \mathcal{D}} (y_i - \tilde{x}_i(T, \theta))^2 \quad (3.9)$$

Come ultima funzione da definire è una per gestire gli errori numerici. Se la scelta delle costanti cinetiche è troppo sbagliata le specie potrebbero molto velocemente divergere a $+\infty$.

Perciò definiamo una funzione che da $+\infty$ nel caso la simulazione è terminata con errori numerici e 0 altrimenti.

$$\mathcal{L}_5(\theta) = \begin{cases} +\infty & \text{se la simulazione è terminata con errori numerici} \\ 0 & \text{altrimenti} \end{cases} \quad (3.10)$$

La funzione finale da minimizzare è:

$$\mathcal{L}(\theta) = \alpha \cdot \mathcal{L}_1(\theta) + \beta \cdot \mathcal{L}_2(\theta) + \gamma \cdot \mathcal{L}_3(\theta) + \zeta \cdot \mathcal{L}_4(\theta) + \mathcal{L}_5(\theta) \quad (3.11)$$

Dove $\alpha, \beta, \gamma, \zeta \in \mathbb{R}$ sono degli iperparametri dell'ottimizzatore per scalare le varie funzioni a seconda se vogliamo vincolare di più l'aderenza ai dati sperimentali (γ o ζ) oppure la stabilità.

3.2 Come trovare i parametri

Per trovare i parametri è equivalente a dire che:

$$\mathcal{S} = \arg \max_{\theta} \mathcal{L}(\theta) \quad (3.12)$$

Dato che il dominio dei parametri è discritto potremmo poter trovare tutti i possibili parametri che rispettano i vincoli, ovvero tale per cui $\mathcal{L}(\theta) \leq \epsilon$ dove $\epsilon > 0$ molto piccolo.

Se i parametri da cercare sono molto pochi allora si può provare a cercare tutte le soluzioni possibili.

Altrimenti si può utilizzare il risultato ottenuto dal progetto di **intelligenza artificiale** per trovare tramite ottimizzazione black box i parametri migliori, anche se la differenza è che qua operiamo nel discreto e non con parametri continui.

Capitolo 4

Progettazione del tool

In Figura 4.1 è mostrato il diagramma UML che evidenzia le componenti centrali del tool che si appoggia al framework apricopt.

Apricopt ha delle interfacce che permettono di modellare problemi di ottimizzazione BlackBox, in particolare quei problemi che richiedono la simulazione di un modello biologico.

Al centro del framework è il BlackBoxSolver, che ha il compito di cercare i parametri ottimali.

Esso è un interfaccia, una classe può essere estesa ad essa per implementare un algoritmo di ottimizzazione, per esempio per quanto riguarda l'algoritmo evolutivo di OpenAI. Oppure si possono usare ottimizzatori terzi come Nevergrad o Nomad.

I problemi black box che stiamo considerando sono la stima dei parametri di un dato modello biologico.

La loss function $\mathcal{L}$ può essere passata attraverso SimulableBlackBox che simula il modello con i parametri θ e calcola $\mathcal{L}(\theta, \mathcal{T}(\theta))$.

4.1 Algoritmo

Algorithm 1 An algorithm with caption

```

1:  $R \subseteq [1, n]^2$ ,  $R$  è una relazione d'ordine sulle specie
2:  $B \in \mathbb{R}$  è il target
3: optimizer  $\leftarrow$  una qualsiasi classe che estende BlackBoxSolver
4: while  $i \in 1..*$  do
5:    $\theta \leftarrow$  optimizer.ask()
6:   Sia  $\mathcal{T}(\theta)$  la traiettoria del sistema
7:   if  $\mathcal{L}(\theta, \mathcal{T}(\theta)) \leq B$  then return  $\theta$ 
8:   end if
9:   optimizer.tell( $\theta, \mathcal{L}(\theta)$ )
10: end while

```




Figura 4.1 UML

Capitolo 5

Esempi di modelli

5.1 Cellule staminali mammarie




Figura 5.1 Rappresentazione del modello: R-HSA-9938206

Questo modello rappresenta lo sviluppo delle cellule staminali mammarie.

Il problema è stato vincolato in modo tale che le specie con id 189869 e 9925889 avessero come concentrazione media 0.1 e che la specie 9925883 fosse la meno espressa.

Si possono vedere i risultati in 5.2

5.2 Ripiegamento proteico mediato da chaperoni nel cancro

Per il modello 5.3 è stata vincolata solo la stabilità e si possono vedere i risultati in 5.4.




Figura 5.2 A sinistra c'è l'ottimizzazione fatta da Nevergrad dei parametri e a destra invece la simulazione.




Figura 5.3 Rappresentazione del modello: R-HSA-390471




Figura 5.4 A sinistra c'è l'ottimizzazione fatta da Nevergrad dei parametri e a destra invece la simulazione.

5.3 Mutazione IDH1 e produzione di 2-idrossiglutarato (R-HSA-2978092)

La mutazione dell'enzima IDH1 nei glioblastomi altera la sua attività: invece di convertire isocitrato in α -chetoglutarato, usa NADPH per trasformare α -chetoglutarato in 2-idrossiglutarato. Questo metabolita anomalo si accumula nelle cellule e può favorirne la crescita tumorale.

5.4 Regolazione dell'apoptosi tramite ubiquitinazione proteica (R-HSA-169911)

L'equilibrio tra sopravvivenza e morte cellulare programmata è cruciale per lo sviluppo e la salute dei tessuti. L'ubiquitinazione e la degradazione delle proteine sono meccanismi chiave che controllano l'attivazione o l'inibizione dell'apoptosi (morte cellulare programmata).

5.5 Patologie legate alla risposta cellulare allo stress

Le cellule devono adattarsi a stress come danni al DNA, carenza di nutrienti o ossigeno e radicali liberi. Quando la risposta è alterata, si sviluppano malattie: la senescenza cellulare può favorire il cancro o contribuire a patologie croniche e legate all'età.

Capitolo 6

Conclusione

6.1 Innovatività della ricerca

6.2 Potenzialità di realizzare un avanzamento delle conoscenze

Bibliografia

Ringraziamenti